

Klasifikasi Gambar Kupu-Kupu Menggunakan *Convolutional Neural Network* (CNN), FractalNet, dan ResNext

Alfa Rizki Fadlillah 2117051003

Jurusan Ilmu Komputer, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Lampung

| KATA KUNCI | ABSTRAK |
|---|--|
| <i>Deep learning</i> , CNN, ResNext, klasifikasi, FractalNet, Kupu-kupu | Penelitian ini membahas penerapan metode pembelajaran mendalam (<i>deep learning</i>) untuk klasifikasi gambar kupu-kupu, menggunakan tiga arsitektur utama: <i>Convolutional Neural Network</i> (CNN), FractalNet, dan ResNext. Studi ini dilakukan untuk mengatasi tantangan dalam klasifikasi spesies kupu-kupu yang memiliki pola visual kompleks dan keragaman tinggi. Dataset yang digunakan terdiri atas 1.252 gambar dari delapan kelas, dengan proses augmentasi untuk meningkatkan variasi data. Hasil percobaan menunjukkan bahwa ResNext memberikan performa terbaik dengan akurasi 97,30%, diikuti oleh FractalNet (95,95%) dan CNN (94,59%). Selain itu, nilai metrik lainnya seperti presisi, recall, dan F1-score menunjukkan keunggulan serupa pada ResNext dibandingkan dua model lainnya. Penelitian ini menyimpulkan bahwa ResNext merupakan pilihan optimal untuk klasifikasi kupu-kupu, sementara CNN dan FractalNet tetap relevan untuk studi kasus dengan kebutuhan yang berbeda. Studi ini diharapkan dapat mendukung pengembangan teknologi berbasis AI dalam identifikasi spesies dan konservasi keanekaragaman hayati. |

1. Pendahuluan

Kupu-kupu memiliki peran penting dalam ekosistem sebagai indikator lingkungan, penyerbuk tanaman, dan objek penelitian dalam biodiversitas. Namun, klasifikasi spesies kupu-kupu menghadapi tantangan akibat keragaman pola visual, kesamaan antarspesies, dan jumlah spesies yang sangat banyak, diperkirakan lebih dari 18.000 di seluruh dunia [1]. Oleh karena itu, pendekatan otomatis

berbasis pembelajaran mesin, khususnya *deep learning*, semakin banyak digunakan untuk mengatasi tantangan ini [2].

Dalam beberapa tahun terakhir, perkembangan teknologi kecerdasan buatan (*Artificial Intelligence/AI*), khususnya pembelajaran mendalam (*Deep Learning*), telah membuka peluang baru dalam berbagai bidang, termasuk dalam pengenalan pola dan

klasifikasi gambar. Deep learning memiliki kemampuan untuk mengekstraksi fitur secara otomatis dari data gambar, sehingga tidak lagi bergantung pada ekstraksi fitur manual yang sering kali kompleks dan memakan waktu. Hal ini menjadikan deep learning sangat potensial untuk diterapkan dalam klasifikasi kupu-kupu.

Beberapa arsitektur deep learning modern, seperti Convolutional Neural Networks (CNN), ResNext, dan FractalNet, telah menunjukkan kinerja yang sangat baik dalam tugas-tugas klasifikasi gambar. CNN, sebagai salah satu model deep learning yang paling populer, dirancang khusus untuk menangani data gambar dan telah digunakan secara luas dalam berbagai aplikasi. ResNext, dengan pendekatan residual yang diperluas, menawarkan peningkatan efisiensi dan akurasi pada model klasifikasi. Sementara itu, FractalNet memanfaatkan struktur jaringan berulang untuk meningkatkan generalisasi model tanpa membutuhkan parameter tambahan yang besar.

Dalam penelitian ini, saya mengeksplorasi penerapan CNN,

ResNext, dan FractalNet untuk klasifikasi kupu-kupu yang dibagi ke dalam delapan kelas. Tujuan utama dari penelitian ini adalah untuk membandingkan performa ketiga model tersebut dalam mengklasifikasikan gambar kupu-kupu, serta mengevaluasi potensi penerapan deep learning dalam mendukung konservasi keanekaragaman hayati dan penelitian ekologi. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi pada pengembangan teknologi berbasis AI dalam identifikasi dan klasifikasi spesies secara otomatis.

2. Penelitian Terkait

Berbagai penelitian telah membahas penggunaan deep learning untuk klasifikasi kupu-kupu. Misalnya, CNN telah terbukti menghasilkan akurasi tinggi dalam mengklasifikasikan spesies kupu-kupu. Dalam penelitian oleh Fauzi et al. (2021), model CNN berhasil mencapai akurasi hingga 97,44% menggunakan model 7-Conv sederhana [2].

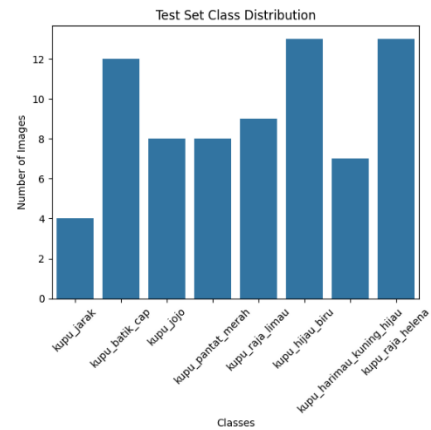
Arsitektur seperti ResNet telah diterapkan untuk klasifikasi dengan hasil yang signifikan. Modifikasi ResNet18, misalnya, mampu meningkatkan sensitivitas terhadap fitur visual spesifik kupu-kupu, mencapai akurasi lebih dari 98% pada dataset tertentu [3]. Selain itu, metode FractalNet menunjukkan potensi dalam menangani kompleksitas pola visual pada dataset yang besar, meskipun aplikasinya dalam klasifikasi kupu-kupu masih jarang dilaporkan.

3. Metodologi

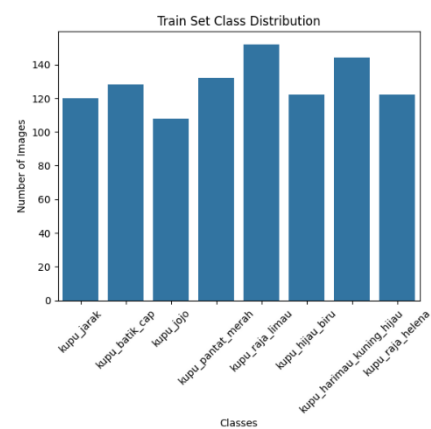
Disini saya akan menjelaskan beberapa metode yang saya gunakan dalam melaksanakan penelitian ini.

3.1. Dataset

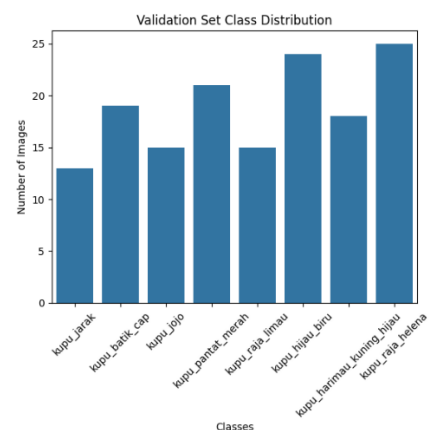
Dataset yang digunakan pada penelitian kali ini adalah dataset berupa gambar kupu-kupu yang terbagi menjadi beberapa kelas. Dataset sendiri diperbanyak dengan proses augmentasi dan di bagi menjadi data train, test, dan validasi. Data train mencakup 1028 gambar, data test 74 gambar dan data validasi 150 gambar. Adapun distribusinya adalah sebagai berikut.



Gambar 1. Distribusi data Test



Gambar 2. Distribusi data Train



Gambar 3. Distribusi data validasi

Jumlah keseluruhan dataset setelah di augmentasi sendiri adalah 1252 gambar, yang dimana gambar tersebut

terbagi menjadi 8 kelas. Diharapkan dengan adanya augmentasi ini dapat memberikan variasi yang dapat meningkatkan performa model saat training nanti. Berikut adalah beberapa sampel dari dataset



Gambar 4. Sampel Dataset

3.2. Pre-processing data

Pada tahapan pre-proses data, ada beberapa teknik yang digunakan, antara lain augmentasi berbentuk *flip* dan *rotate*, lalu gambar juga dilakukan auto orientasi, dan di *resize* ukurannya dari yang tadinya 6000x4000 piksel, menjadi 224x224 pixel yang diharapkan dapat mempercepat waktu komputasi training tanpa mengorbankan performa model.

3.3. Convolutional Neural Network (CNN)

Convolutional Neural Networks (CNN) adalah jenis jaringan saraf tiruan yang dirancang khusus untuk menangani data grid-struktur seperti gambar dua dimensi. CNN memiliki

keunggulan utama dalam menangkap hubungan spasial lokal melalui operasi konvolusi, yang memungkinkan jaringan untuk mengenali pola penting seperti tepi dan tekstur dalam gambar. Arsitektur CNN mencakup lapisan-lapisan seperti lapisan konvolusi, lapisan pooling, dan lapisan fully connected, yang bekerja bersama untuk mengekstraksi, mengabstraksi, dan mengklasifikasikan fitur dari input. Teknologi ini telah diterapkan secara luas dalam berbagai bidang, termasuk pengenalan objek, pemrosesan bahasa alami, dan pengenalan suara, dengan hasil yang luar biasa dalam meningkatkan akurasi tugas pembelajaran mesin [4][5].

Komponen inti CNN termasuk fungsi aktivasi non-linear, yang memungkinkan model menangkap pola kompleks dalam data, dan metode regulasi seperti dropout untuk mengurangi overfitting. Dalam dunia medis, CNN telah digunakan untuk menganalisis gambar radiologi guna meningkatkan kemampuan diagnostik, sementara di bidang teknologi, CNN telah dioptimalkan untuk pengenalan objek skala besar menggunakan dataset seperti ImageNet [6][7]. Kemajuan dalam hardware, seperti

unit pemrosesan grafis (GPU), turut mempercepat pelatihan CNN, menjadikannya salah satu alat paling andal dalam pembelajaran mendalam saat ini.

3.4. FractalNet

FractalNet adalah arsitektur jaringan saraf dalam yang dirancang untuk menangani tantangan overfitting dan pelatihan dalam model deep learning. Menggunakan pendekatan berbasis self-similarity, FractalNet membangun jaringan yang lebih dalam dan lebih lebar dengan mengulang blok fractal secara rekursif. Pendekatan ini memungkinkan keseimbangan antara kedalaman dan lebar jaringan, sehingga meningkatkan kemampuan generalisasi tanpa memerlukan teknik regulasi tambahan seperti dropout. Penelitian menunjukkan bahwa arsitektur FractalNet dapat meningkatkan performa deteksi steganalitik dan tugas klasifikasi lainnya dengan signifikan, terutama dalam skenario di mana kedalaman jaringan harus disesuaikan dengan proporsi lebar jaringan [8].

3.5. ResNext

ResNeXt adalah varian dari ResNet yang menggunakan pendekatan arsitektur berbasis transformasi residual teragregasi untuk meningkatkan kemampuan representasi model tanpa meningkatkan kompleksitas parameter secara signifikan. ResNeXt memperkenalkan konsep cardinality, yaitu jumlah transformasi paralel yang dilakukan dalam satu blok, yang terbukti lebih efektif dalam meningkatkan kinerja model dibandingkan dengan hanya memperdalam atau memperlebar jaringan. Dalam tugas pengenalan gambar seperti ImageNet, ResNeXt menunjukkan bahwa peningkatan cardinality memberikan hasil yang lebih baik dibandingkan peningkatan kedalaman atau lebar jaringan dengan jumlah parameter yang sama [9]. Pendekatan ini telah diterapkan dalam berbagai domain, termasuk deteksi malware dan pengenalan pola, dengan hasil yang unggul dalam klasifikasi akurasi tinggi [10].

4. Hasil

4.1. *Convolutional Neural Network (CNN)*

Hasil yang didapatkan oleh CNN pada percobaan kali ini tergolong sangat baik, dengan akurasi sebesar 94,59%, bahkan pada fase traning CNN dapat menyentuh akurasi 99,80% dan 98% pada validasinya. Hal ini menunjukkan bahwa model dapat mempelajari pola dari dataset dengan baik. Selain akurasi CNN juga mendapatkan nilai bagus di penilaian metrik yang lain, seperti Presisi sebesar 95,63%, Recall sebesar 94,95%, dan F1-score sebesar 94,67%.

| | Metric | Value |
|---|-----------|----------|
| 0 | Accuracy | 0.945946 |
| 1 | Precision | 0.956294 |
| 2 | Recall | 0.949519 |
| 3 | F1-Score | 0.946989 |

Gambar 5. Metrik Evaluasi CNN

4.2. FractalNet

Hasil yang didapatkan oleh FractalNet dapat melebihi CNN dinilai dari segi metrik evaluasinya. FractalNet mendapatkan nilai akurasi sebesar 95,95%, Presisi sebesar 97%, Recall sebesar 96%, dan F1-score sebesar 96%. Dari hasil evaluasi metrik tersebut dapat disampaikan bahwa FractalNet pada studi kasus kupu-

kupu ini dapat melampaui performa CNN dalam klasifikasi.

```
Test Metrics:
Accuracy: 95.95%
Precision: 0.97
Recall: 0.96
F1-Score: 0.96
```

Gambar 6. Metrik Evaluasi
FractalNet

4.3. ResNext

Pada penelitian kali ini dengan menggunakan studi kasus kupu-kupu yang telah dijelaskan sebelumnya, ResNext mendapatkan performa yang paling tinggi dibanding metode yang lain pada penelitian kali ini, ResNext mendapatkan nilai akurasi sebesar 97,30%, Presisi sebesar 98%, Recall sebesar 97%, dan F1-score sebesar 97%, dengan performa tersebut dapat disimpulkan bahwa pada percobaan kali ini ResNext dapat memberikan hasil klasifikasi yang paling baik dibandingkan dengan FractalNet dan juga CNN.

```
Test Metrics:
Accuracy: 97.30%
Precision: 0.98
Recall: 0.97
F1-Score: 0.97
```

Gambar 7. Metrik Evaluasi ResNext

5. Kesimpulan

Pada penelitian kali ini yang membahas klasifikasi kupu-kupu menggunakan metode CNN, FractalNet, dan ResNext, didapatkan kesimpulan bahwa ResNext menjadi metode yang memiliki kemampuan klasifikasi yang lebih baik dibandingkan CNN dan FractalNet, walaupun begitu tidak dipungkiri juga bahwa performa yang disajikan oleh CNN dan FractalNet tidak terlampau jauh sehingga dengan kondisi tertentu bisa saja menjadi solusi yang lebih optimal di studi kasus yang lain.

Diharapkan hasil penelitian ini dapat membantu dalam pemilihan arsitektur *Deep Learning* dalam melakukan klasifikasi di studi kasus yang lain.

Daftar Pustaka

- [1] Zhao, R., Li, C., Ye, S., & Fang, X. (2019). Butterfly Recognition Based on Faster R-CNN. *Journal of Physics: Conference Series*, 1176. <https://doi.org/10.1088/1742-6596/1176/3/032048>.
- [2] Fauzi, F., Permanasari, A., & Setiawan, N. (2021). Butterfly Image Classification Using Convolutional Neural Network (CNN). *2021 3rd International Conference on Electronics Representation and Algorithm (ICERA)*, 66-70. <https://doi.org/10.1109/ICERA53111.2021.9538686>.
- [3] Sar, A., Choudhury, T., Aich, S., Joshi, P., Pant, B., Dewangan, B., & Choudhury, T. (2024). Butterfly Image Classification using Modification and Fine-Tuning of ResNet18. *2024 OPJU International Technology Conference (OTCON) on Smart Computing for Innovation and Advancement in Industry 4.0*, 1-6. <https://doi.org/10.1109/OTCON60325.2024.10688302>.
- [4] Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2020). A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *IEEE Transactions on Neural Networks and Learning Systems*, 33, 6999-7019. <https://doi.org/10.1109/TNNLS.2021.3084827>.
- [5] Yamashita, R., Nishio, M., R., & Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology. *Insights into Imaging*, 9, 611 - 629.

- <https://doi.org/10.1007/s13244-018-0639-9>.
- [6] Krizhevsky, A., Sutskever, I., & Hinton, G. (2012). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, 60, 84 - 90.
<https://doi.org/10.1145/3065386>.
- [7] Gu, J., Wang, Z., Kuen, J., , L., Shahroudy, A., Shuai, B., Liu, T., Wang, X., Wang, G., Cai, J., & Chen, T. (2015). Recent advances in convolutional neural networks. *Pattern Recognit.*, 77, 354-377.
<https://doi.org/10.1016/J.PATCOG.2017.10.013>.
- [8] Singh, B., Sur, A., & Mitra, P. (2021). Steganalysis of Digital Images Using Deep Fractal Network. *IEEE Transactions on Computational Social Systems*, 8, 599-606.
<https://doi.org/10.1109/TCSS.2021.3052520>.
- [9] Xie, S., Girshick, R., Dollár, P., Tu, Z., & He, K. (2016). Aggregated Residual Transformations for Deep Neural Networks. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 5987-5995.
<https://doi.org/10.1109/CVPR.2017.634>.
- [10] He, Y., Kang, X., Yan, Q., & Li, E. (2024). ResNeXt+: Attention Mechanisms Based on ResNeXt for Malware Detection and Classification. *IEEE Transactions on Information Forensics and Security*, 19, 1142-1155.
<https://doi.org/10.1109/TIFS.2023.3328431>.